

دانشگاه صنعتی خواجه نصیرالدین طوسی

پروژه درس یادگیری ماشین

طراحی جانشین یادگیری نظارت شده برای بهینه سازی مشترک

ارتفاع و شکل موج در سامانه UAV-ISWPT

A Supervised Learning Surrogate for Joint Waveform and Altitude Optimization in UAV-Enabled ISWPT Systems

دانشجو: مهدی اصلانی

شماره دانشجویی: ۴۰۳۰۱۹۰۴

استاد درس: دکتر علی یاری

مرداد ۱۴۰۵

چکیده

در سامانه‌های یکپارچه حسگری و انتقال توان بی‌سیم مبتنی بر پهپاد، ارتفاع پرواز و ماتریس کوواریانس سیگنال‌رسانی به یکدیگر وابسته‌اند. ارتفاع مناسب می‌تواند مسیر انتشار را برای تجهیزات برداشت‌کننده انرژی بهبود دهد، اما هم‌زمان الگوی پرتوی رادار و کیفیت حسگری را نیز تغییر می‌دهد. حل مرجع مقاله Kang این مسئله را با یک جست‌وجوی بیرونی روی ارتفاع و حل یک برنامه نیمه‌معین برای هر ارتفاع انجام می‌دهد؛ روشی دقیق، اما برای استفاده تکرارشونده پرهزینه است.

در این پروژه، به جای حذف کامل مدل فیزیکی، از یک ساختار ترکیبی استفاده شده است. مدل یادگیری ماشین تنها ارتفاع مناسب را از روی هشت ویژگی هندسی و کنترلی پیش‌بینی می‌کند و پس از آن، شکل موج با حل دقیق مسئله محدب در همان ارتفاع محاسبه می‌شود. این انتخاب باعث می‌شود امکان‌پذیری فیزیکی شکل موج حفظ شود و در عین حال تعداد حل‌های سنگین به شدت کاهش یابد.

داده شامل ۱۰۰۰ سناریوی بازتولیدپذیر است. چهار مدل رگرسیون خطی، درخت تصمیم، SVR با هسته RBF و شبکه عصبی MLP بررسی شدند. در پنج تقسیم مستقل، SVR با میانگین MAE برابر $7/88$ متر پایدارترین عملکرد را داشت. در ارزیابی ۲۰۰ نمونه‌ای تابع هدف، میانگین شکاف SVR برابر $0/793$ درصد بود. در ممیزی دقیق ۲۰ نمونه، MLP کمترین شکاف میانگین را به دست آورد، اما SVR در ارزیابی گسترده‌تر و مقایسه مستقیم با سناریوی مقاله رفتار متعادل‌تری نشان داد.

به عنوان جمع‌بندی می‌توان گفت خروجی پروژه یک جایگزین کاملاً بدون حل‌گر نیست؛ بلکه یک روش ترکیبی است که جست‌وجوی پرهزینه ارتفاع را با پیش‌بینی توسط یادگیری ماشین جایگزین می‌کند و برای حفظ قیود، تنها یک حل دقیق در ارتفاع پیش‌بینی‌شده انجام می‌دهد.

واژگان کلیدی:

UAV، ISWPT، رگرسیون، SVR، برنامه‌ریزی نیمه‌معین، بهینه‌سازی ارتفاع، شکاف بهینگی.



فهرست مطالب

صفحه	عنوان
۱	چکیده
۲	فهرست مطالب
۳	نمادها و اختصارات
۵	۱. مقدمه و بیان مسئله
۶	۲. مبانی و کارهای مرتبط
۸	۳. مدل سامانه UAV-ISWPT
۹	۴. فرمول‌بندی ریاضی مسئله
۱۰	۵. حل مرجع و حل گر سریع
۱۱	۶. روش پیشنهادی یادگیری ماشین
۱۲	۷. تولید و کنترل کیفیت داده
۱۳	۸. مدل‌ها و انتخاب ابرپارامتر
۱۵	۹. پروتکل ارزیابی
۱۶	۱۰. نتایج پیش‌بینی ارتفاع
۱۷	۱۱. ارزیابی مهندسی تابع هدف
۱۹	۱۲. تحلیل اهمیت ویژگی‌ها
۲۰	۱۳. مقایسه با مقاله Kang
۲۳	۱۴. اعتبارسنجی و بازتولیدپذیری



۲۴	۱۵. بحث، محدودیت‌ها و کار آینده
۲۵	۱۶. جمع‌بندی
۲۶	منابع
۲۷	پیوست: راهنمای اجرا

نمادها و اختصارات

تعریف	نماد
وسیله پرنده بدون سرنشین	UAV
حسگری یکپارچه و انتقال توان بی‌سیم	ISWPT
انتقال توان بی‌سیم	WPT
رادار چندورودی-چندخروجی	MIMO Radar
تجهیز برداشت‌کننده انرژی	EHD
برنامه‌ریزی نیمه‌معین	SDP
بهینه‌سازی ازدحام ذرات	PSO
رگرسیون بردار پشتیبان	SVR
پرسپترون چندلایه	MLP
مسئله مشترک شکل موج، ضریب مقیاس و ارتفاع	P_1
زیرمسئله محدب شکل موج برای ارتفاع ثابت	$P_2 h$
وزن مبادله میان حسگری راداری و انتقال توان	ρ
ماتریس کوواریانس شکل موج ارسالی	X
ارتفاع پهپاد	h



توجه : زاویه‌ها در داده بر حسب درجه و در روابط داخلی برنامه بر حسب رادیان هستند. ارتفاع و فاصله بر حسب متر گزارش می‌شوند.

۱. مقدمه و بیان مسئله

پهپادها به دلیل امکان جابه‌جایی در فضای سه‌بعدی می‌توانند نقش یک سکوی هوایی انعطاف‌پذیر را برای حسگری و تأمین انرژی ایفا کنند. در یک سامانه UAV-ISWPT، همان آرایه آنتنی و همان طیف فرکانسی باید هم الگوی پرتوی مناسب برای آشکارسازی هدف‌ها را ایجاد کند و هم توان کافی را به تجهیزات زمینی برساند. این دو هدف همیشه هم‌جهت نیستند؛ شکلی از موج که برای رادار مطلوب است الزاماً بیشترین انرژی را در جهت دستگاه‌های زمینی نمی‌فرستد.

ارتفاع نیز یک متغیر صرفاً هندسی نیست. افزایش ارتفاع می‌تواند احتمال دید مستقیم را بیشتر کند، ولی فاصله انتشار را نیز افزایش می‌دهد. در نتیجه تابع هدف نسبت به ارتفاع رفتاری غیرخطی و غیرمحدب دارد. در روش مرجع، برای هر ارتفاع آزمایشی یک مسئله SDP حل می‌شود و یک الگوریتم بیرونی مانند PSO بهترین ارتفاع را جست‌وجو می‌کند. این ساختار برای تولید پاسخ دقیق مناسب است، اما وقتی هزاران سناریو یا تصمیم سریع مطرح باشد، هزینه زمانی آن مسئله‌ساز می‌شود.

۱-۱. سؤال اصلی پروژه

آیا می‌توان از سناریوهای حل‌شده قبلی یاد گرفت و ارتفاعی را پیش‌بینی کرد که پس از حل تنها یک مسئله P_2 ، تابع هدفی نزدیک به جواب جست‌وجوی کامل ایجاد کند؟

۲-۱. گام‌های اصلی که انجام دادم

- تبدیل مسئله غیرمحدب بیرونی به یک مسئله رگرسیون ارتفاع، بدون کنار گذاشتن قیود فیزیکی شکل موج.
- تولید مجموعه داده بزرگ‌گذاری شده و ممیزی کیفیت حل گر سریع و برچسب‌های ارتفاع.
- مقایسه چهار مدل با انتخاب ابرپارامتر فقط روی داده آموزش و پنج تقسیم مستقل.
- ارزیابی هم‌زمان خطای ارتفاع و شکاف واقعی تابع هدف P_1 .
- مقایسه مستقیم با Algorithm ۱ و Algorithm ۲ مقاله Kang روی شبکه زاویه 0.1° درجه.

۲. مبانی و کارهای مرتبط


۱-۲. مدل Kang

Kang در سال ۲۰۲۴ مسئله طراحی مشترک شکل موج و ارتفاع را برای سامانه UAV-ISWPT فرمول‌بندی کرد [۱]. در روش ۱ Algorithm، جست‌وجوی PSO روی ارتفاع انجام می‌شود و برای هر ذره، مسئله SDP متناظر با ارتفاع ثابت حل می‌گردد. مقاله همچنین ۲ Algorithm را با ساختار محدودتر شکل موج در رابطه (۳۷) ارائه می‌کند تا تعداد و اندازه محاسبات کاهش یابد.




Figure 1. Illustration of UAV-enabled integrated RadWPT system.

شکل ۱ - ساختار سامانه یکپارچه حسگری راداری و انتقال توان بی‌سیم مبتنی بر پهپاد. منبع: [۱، شکل ۱].



(a) Objective function value.



شکل ۲ - مقایسه روند تابع هدف در سناریوی ۱: (الف) نتایج مقاله Kang، شکل ۳(a)؛ (ب) بازتولید و توسعه این پروژه روی شبکه زاویه‌ای ۰/۱ درجه.



روند تغییر تابع هدف روش پیشنهادی با رفتار گزارش شده در مقاله سازگار است. با این حال، هدف این پروژه بازتولید پیکسل به پیکسل نمودار مقاله نیست؛ زیرا پیاده سازی، تفکیک شبکه، حل گر و معیار ممیزی مستقل هستند. نزدیکی Algorithm 2، ممیزی Algorithm 1 و روش SVR+P2 نشان می دهد که پیش بینی ارتفاع، پس از حل دقیق زیرمسئله P2، افت مهندسی محدودی ایجاد می کند.

۲-۲. یادگیری برای بهینه سازی

مرجع Learning to Optimize تأکید می کند که روش های داده محور زمانی ارزشمند هستند که یک خانواده مشخص از مسائل بارها حل شود [۳]. مزیت اصلی، انتقال هزینه به مرحله آموزش آفلاین است؛ اما همان مرجع درباره افت عملکرد خارج از توزیع آموزش هشدار می دهد. به همین دلیل، ارزیابی این پروژه به دامنه نمونه برداری شده محدود شده و اعتبارسنجی OOD به عنوان کار آینده در نظر گرفته شده است.

۲-۳. شبکه عصبی در سامانه های بی سیم و پهنای

مرجع آموزشی Chen و همکاران نشان می دهد که آموزش آفلاین و استقرار مدل سبک روی تجهیزات محدود می تواند تأخیر و مصرف انرژی را کاهش دهد [۴]. در عین حال، کیفیت داده، محدودیت محاسباتی پهنای و تغییر محیط از چالش های کلیدی باقی می ماند. این نکته دلیل استفاده از چند مدل ساده و قابل تفسیر در کنار MLP است، نه تکیه صرف بر یک شبکه عمیق.

تفاوت با پروپوزال اولیه: پروپوزال از پیش بینی مستقیم ارتفاع و وزن های ارسال و استفاده از PCA نام می برد. نسخه نهایی، با هدف حفظ امکان پذیری، فقط ارتفاع را یاد می گیرد و شکل موج را با حل فیزیکی محاسبه می کند؛ همچنین به جای PCA از permutation importance استفاده شده است.

۳. مدل سامانه UAV-ISWPT

یک پهپاد مجهز به آرایه خطی یکنواخت با $N=8$ آنتن در ارتفاع h قرار دارد. سه جهت هدف راداری و دو تجهیز برداشت‌کننده انرژی در هر سناریو تعریف می‌شوند. بردار هدایت آرایه برای زاویه θ به صورت زیر نوشته می‌شود:

$$a(\theta) = \left[1, e^{-j2\pi\left(\frac{d_a}{\lambda}\right)\sin\theta}, \dots, e^{-j2\pi\left(\frac{d_a}{\lambda}\right)(N-1)\sin\theta} \right] \quad (1)$$

پرتو حاصل از ماتریس کوواریانس X برابر است با:

$$P_{Rad}(\theta; X) = a^H(\theta) X a(\theta) \quad (2)$$

برای هر تجهیز u ، فاصله سه‌بعدی، زاویه ارتفاع، احتمال دید مستقیم و ضریب ریس به ارتفاع وابسته‌اند. مدل پیاده‌سازی شده با روابط مقاله Kang سازگار است:

$$d_{u(h)} = \sqrt{r_u^2 + h^2}, \quad \psi_{u(h)} = \arctan\left(\frac{h}{r_u}\right) \quad (3)$$

$$P_{LoS}(\psi) = \frac{1}{\left[1 + a_1 \exp\left(-b_1\left(\frac{180\psi}{\pi} - a_1\right)\right)\right]} \quad (4)$$

$$G_u(h) = \beta_0 d_{u(h)}^{-\alpha_u} \left[\frac{K_u}{(K_u+1)} a a^H + \frac{1}{(K_u+1)} I \right] \quad (5)$$

پارامتر	مقدار
تعداد آنتن N	۸
توان کل P_T	۱ W
فاصله آنتن $\frac{d_a}{\lambda}$	۰.۵
بازه ارتفاع	۵۰ تا ۲۵۰ متر
پهنای پرتو مطلوب	۱۰°
شبکه اصلی آموزش	۱۰°
شبکه مقایسه مقاله	۰.۱°

۴. فرمول بندی ریاضی مسئله

۴-۱. تابع خطای رادار

$$L_{Rad(X,\gamma)} = \left(\frac{1}{L}\right) \sum_l [\gamma \chi(\theta_l) - a^H(\theta_l) X a(\theta_l)]^2 \quad (۶)$$

۴-۲. تابع خطای انتقال توان

$$L_{WPT(X,h)} = \left(\frac{1}{U}\right) \sum_u \left[1 - \frac{Tr(G_u(h)X)}{p_u^{Des}}\right]^2 \quad (۷)$$

۴-۳. مسئله مشترک P1

$$P1: \min_{\{X,\gamma,h\}} \rho L_{Rad(X,\gamma)} + (1 - \rho) L_{WPT(X,h)} \quad (۸)$$

$$s. t. [X]_{\{n,n\}} = \frac{P_T}{N}, \forall n; \quad X \geq 0; \quad H_{min} \leq h \leq H_{max} \quad (۹)$$

پارامتر ρ مبادله میان دو وظیفه را تعیین می کند. وقتی ρ به یک نزدیک می شود، خطای رادار اهمیت بیشتری دارد و وقتی به صفر نزدیک می شود، تطبیق توان برداشت شده در اولویت است. غیرمحدب بودن P1 عمدتاً از وابستگی پیچیده $G_u(h)$ به ارتفاع ناشی می شود.

۴-۴. زیرمسئله محدب P2 در ارتفاع ثابت

$$P2|h: \min_{\{X,\gamma\}} \rho L_{Rad(X,\gamma)} + (1 - \rho) L_{WPT(X,h)} \quad (۱۰)$$

$$s. t. \text{diag}(X) = \frac{P_T}{N} \cdot \mathbf{1}, \quad X \geq 0 \quad (۱۱)$$

مدل ML مقدار h را پیشنهاد می دهد، اما X و γ همچنان از P2|h به دست می آیند. بنابراین قیود PSD و توان هر آنتن به صورت صریح حفظ می شوند.

۵. حل مرجع و حل گر سریع

۵-۱. حل مرجع

کلاس FixedAltitudeSDP مسئله P_2 را با CVXPY پیاده سازی می کند. مسئله هم DCP و هم DPP تشخیص داده شد و در ممیزی ها از Clarabel به عنوان حل گر مخروطی استفاده شد. این حل گر برای ارزیابی نهایی و کنترل امکان پذیری مناسب است، اما اجرای هزاران باره آن هزینه زمانی بالایی دارد.

۵-۲. حل گر تقریبی سریع

برای تولید انبوه داده و ساخت oracle مشترک، از روش FISTA/Dykstra استفاده شده است. بخش FISTA تابع نرم را کاهش می دهد و فرافکنی Dykstra ماتریس را به اشتراک دو مجموعه محدب — PSD بودن و قطر ثابت — باز می گرداند. این حل گر پاسخ دقیق را حذف نمی کند؛ بلکه برای مرحله سنگین، یک تقریب کنترل شده ارائه می دهد.

معیار ممیزی حل گر سریع	120fast	500fast
میانۀ خطای نسبی مطلق	0.0254%	0.0227%
صدک ۹۵ خطای نسبی مطلق	0.1758%	0.1799%
بیشینه خطای نسبی مطلق	0.2138%	0.2082%
بیشینه خطای قطر	0	0
کمینه مقدار ویژه	6.35×10^{-6}	6.35×10^{-6}

این نتایج نشان می دهد تقریب سریع در ۲۰ سناریوی ممیزی، قیود اصلی را حفظ کرده و خطای تابع هدف آن کمتر از حدود ۰/۲۲ درصد باقی مانده است.

۶. روش پیشنهادی یادگیری ماشین

روش پیشنهادی از یک زنجیره ترکیبی تشکیل شده است. ورودی مدل، شرح فشرده سناریو است و خروجی آن تنها ارتفاع است. سپس یک حل P_2 در همان ارتفاع، شکل موج نهایی را تولید می‌کند.

۱. سناریوی هندسی شامل زاویه‌های هدف، فاصله و زاویه تجهیزات و مقدار ρ دریافت می‌شود.
۲. دو تجهیز بر اساس فاصله مرتب می‌شوند و زاویه هر تجهیز همراه آن جابه‌جا می‌گردد؛ بنابراین تقارن نام‌گذاری حفظ می‌شود.
۳. مدل رگرسیون ارتفاع $\hat{h}$ را پیش‌بینی و آن را به بازه ۵۰ تا ۲۵۰ متر محدود می‌کند.
۴. مسئله دقیق $P_2|\hat{h}$ یک‌بار حل می‌شود تا X و γ سازگار با قیود به دست آیند.
۵. تابع هدف P_1 با پاسخ حاصل محاسبه و با oracle همان سناریو مقایسه می‌شود.

$$z = [\theta_1, \theta_2, \theta_3, r_{near}, r_{far}, \varphi_{near}, \varphi_{far}, \rho] \rightarrow \hat{h} = f_{ML(z)} \quad (12)$$

$$(\hat{X}, \hat{\gamma}) = \arg \min P_2|\hat{h} \quad (13)$$

چرا این ساختار انتخاب شد؟ پیش‌بینی مستقیم یک ماتریس مختلط PSD با قطر ثابت دشوار است و امکان تولید پاسخ نامعتبر دارد. پیش‌بینی ارتفاع، فضای خروجی را تک‌بعدی نگه می‌دارد و امکان‌پذیری را به حل‌گر فیزیکی واگذار می‌کند.

۷. تولید و کنترل کیفیت داده

مجموعه داده اصلی در $ds^3.npz$ ذخیره شده و شامل ۱۰۰۰ نمونه، هشت ویژگی، برچسب ارتفاع y_H و مقدار تابع هدف y_O است. سناریوی شماره i با بذر $i+90000$ تولید می شود؛ بنابراین ویژگی های همه نمونه ها قابل بازتولید هستند. داده فاقد NaN، مقدار بی نهایت و ردیف تکراری است.

ویژگی	معنا	نقش
$\theta_1, \theta_2, \theta_3$	سه جهت هدف راداری	تعیین الگوی مطلوب
r_{near}, r_{far}	EHD فاصله افقی دو	عامل غالب ارتفاع مناسب
$\varphi_{near}, \varphi_{far}$	EHD زاویه دو	جهت انتقال توان
ρ	وزن رادار/توان	کنترل مبادله تابع هدف

۷-۱. جست و جوی برچسب ارتفاع

برای هر سناریو ابتدا یک شبکه سراسری و سپس یک شبکه محلی بررسی می شود. در نسخه ذخیره شده، برچسب ها روی شبکه ای گسسته قرار دارند؛ به همین دلیل مدل ها عملاً یک تابع پیوسته را از روی برچسب های تقریب زده یاد می گیرند.

۷-۲. ممیزی برچسب ها

مقدار	معیار
2.269 m	MAE ارتفاع نسبت به ممیزی دقیق
1.944 m	میان خطای ارتفاع
5.333 m	بیشینه خطای ارتفاع
0.0633%	میانگین شکاف P_1
0.2221%	صدک ۹۵ شکاف P_1



بیشینه شکاف P1	0.2428%
----------------	---------

۸. مدل‌ها و انتخاب ابرپارامتر

چهار مدل با ظرفیت‌های متفاوت بررسی شدند تا مشخص شود پیچیدگی بیشتر الزاماً به عملکرد مهندسی بهتر منجر می‌شود یا نه. ویژگی‌ها برای مدل‌های حساس به مقیاس استاندارد شدند. انتخاب ابرپارامتر فقط روی بخش آموزش و با اعتبارسنجی متقاطع پنج‌تایی انجام شد.

مدل	ساختار نهایی	تفسیر
Linear Regression	StandardScaler + LinearRegression	خط پایه ساده و کم‌هزینه
Decision Tree	depth=8, min_leaf=8	غیرخطی و قابل تفسیر
SVR (RBF)	C=300, $\gamma=0.03$, $\epsilon=4$	مدل نهایی پایدار
MLP	(128,64), $\alpha=0.01$	تقریب‌گر غیرخطی انعطاف‌پذیر

۸-۱. جلوگیری از نشت اطلاعات

برای جلوگیری از نشت اطلاعات، استانداردسازی ویژگی‌ها درون Pipeline قرار گرفت؛ بنابراین پارامترهای StandardScaler فقط با داده‌های آموزشی هر fold محاسبه شدند. تنظیم ابرپارامترها نیز صرفاً روی بخش آموزشی انجام شد و مجموعه آزمون تا پایان فرایند انتخاب مدل دست‌نخورده باقی ماند.

- تقسیم اصلی ۸۰۰ آموزش و ۲۰۰ آزمون با بذر ۴۲ است.
- GridSearchCV فقط داده آموزش را مشاهده می‌کند.
- پیش‌پردازش EHDها پیش از آموزش، تقارن فیزیکی جابه‌جایی نام دو دستگاه را اعمال می‌کند.
- ارزیابی نهایی با پیش‌بینی‌های مجموعه آزمون انجام می‌شود.
- برای تحلیل پایداری، پنج بذر مستقل ۷، ۱۹، ۴۲، ۷۳ و ۱۰۱ استفاده شده‌اند.

۹. پروتکل ارزیابی

۹-۱. معیارهای رگرسیون

$$MAE = \left(\frac{1}{n}\right) \sum_i |h_i - \hat{h}_i| \quad (۱۴)$$

$$RMSE = \sqrt{\left[\left(\frac{1}{n}\right) \sum_i (h_i - \hat{h}_i)^2\right]} \quad (۱۵)$$

$$R^2 = 1 - \frac{\sum_i^2 (h_i - \hat{h}_i)}{\sum_i^2 (h_i - \bar{h})} \quad (۱۶)$$

۹-۲. معیار مهندسی

$$Gap(\%) = 100 \times \frac{[F(\hat{h}) - F(h_{oracle})]}{F(h_{oracle})} \quad (۱۷)$$

برای ۲۰۰ نمونه آزمون، oracle سریع از شبکه سراسری ۱۱ نقطه‌ای، برچسب ذخیره‌شده، همه پیش‌بینی‌ها و یک پالایش محلی ۵ متری ساخته می‌شود. برای کنترل حساسیت، ۲۰ نمونه ثابت با P۲ دقیق و شبکه محلی دو متری دوباره محاسبه شدند.


۹-۳. دلیل گزارش هر دو معیار

خطای ارتفاع به‌تنهایی اهمیت مهندسی خطا را نشان نمی‌دهد. در بخشی از فضا، تابع هدف نسبت به ارتفاع تخت است و چند متر خطا تقریباً هیچ هزینه‌ای ندارد؛ در نقطه‌ای دیگر، همان خطا ممکن است افت محسوسی ایجاد کند. بنابراین رتبه‌بندی بر اساس MAE و رتبه‌بندی بر اساس شکاف P۱ باید جداگانه دیده شوند.



۱۰. نتایج پیش‌بینی ارتفاع

مدل	MAE (m)	RMSE (m)	R^2
Linear	7.964	14.453	0.8586
Decision Tree	9.908	16.978	0.8048
SVR (RBF)	7.991	15.657	0.8340
MLP	8.963	15.122	0.8452




شکل ۳

نمودارهای برابری ارتفاع پیش‌بینی شده و برچسب ذخیره شده در تقسیم آزمون

۱-۱۰. پایداری در پنج تقسیم مستقل

مدل	میانگین MAE (m)	انحراف معیار (m)
Linear	8.472	0.651
Decision Tree	10.497	0.957
SVR (RBF)	7.880	0.665
MLP	9.406	0.900

در تقسیم ثابت بذر ۴۲، رگرسیون خطی اندکی MAE کمتری از SVR دارد. با این حال، میانگین پنج تقسیم نشان می‌دهد SVR پایدارتر است و بهترین خطای متوسط را ثبت می‌کند. این تفاوت دلیل انتخاب SVR به عنوان مدل اصلی مقایسه با مقاله است.




شکل ۴

مقایسه خطای ارتفاع و میانگین جریمه تابع هدف برای چهار مدل

۱۱. ارزیابی مهندسی تابع هدف

مدل	میانگین	میانه	صدک ۹۵	بیشینه
Linear	0.867%	0.128%	5.013%	27.356%
Decision Tree	2.145%	0.264%	6.870%	132.288%
SVR (RBF)	0.793%	0.081%	3.308%	38.300%
MLP	1.019%	0.203%	4.145%	29.479%



شکل ۵

توزیع شکاف نسبت به oracle سریع برای ۲۰۰ نمونه آزمون. نقاط دورافتاده در نمایش جعبه‌ای برای خوانایی بریده شده‌اند، اما در آمار جدول حفظ شده‌اند.

تفسیر: SVR بهترین میانگین و میانه را دارد، اما وجود بیشینه‌های بزرگ نشان می‌دهد میانگین کم به تنهایی برای ادعای ایمنی کافی نیست. گزارش صدک ۹۵ و بیشینه ضروری است.

۱۱-۱. ممیزی دقیق ۲۰ نمونه

برای جلوگیری از وابستگی نتیجه به حل گر تقریبی، ۲۰ موقعیت آزمون با CVXPY و مجموعه کاندیدای دقیق تر ارزیابی شدند. نتایج این زیرمجموعه با نتیجه ۲۰۰ نمونه ای یکسان نیست و باید جداگانه تفسیر شود.

مدل	میانگین شکاف	میان	صدک ۹۵	بیشینه
Linear	1.677%	0.231%	6.622%	15.047%
Decision Tree	1.914%	0.242%	6.205%	13.572%
SVR (RBF)	1.342%	0.111%	4.980%	10.396%
MLP	0.834%	0.202%	4.133%	4.691%


MLP در این زیرمجموعه بهترین میانگین شکاف را دارد، در حالی که SVR در مجموعه ۲۰۰ نمونه ای بهترین نتیجه را نشان می دهد. انتخاب مدل نهایی با تکیه بر یک زیرمجموعه کوچک می تواند ناپایدار باشد؛ بنابراین SVR بر اساس پایداری تقسیم ها، ارزیابی ۲۰۰ نمونه ای و بنچمارک مقاله انتخاب شده است.

هشدار عددی: در یکی از حل های ممیزی دقیق، CVXPY هشدار «solution may be inaccurate» ثبت کرد. اجرا متوقف نشد، تمام ۲۰ نمونه کامل شدند و اختلاف بین دو محیط اجرا در مقیاس حدود 10^{-6} واحد درصد باقی ماند.

۱۲. تحلیل اهمیت ویژگی‌ها

به جای PCA از permutation importance روی مدل SVR استفاده شد. در این روش، مقادیر یک ویژگی در مجموعه آزمون به صورت تصادفی جابه‌جا می‌شوند و افزایش MAE اندازه‌گیری می‌شود. بنابراین نتیجه مستقیماً با مدل نهایی و معیار خطا مرتبط است.

اهمیت جایگشتی یک معیار پیش‌بینی است، نه معیار علیت فیزیکی. مقدار گزارش شده نشان می‌دهد جابه‌جایی هر ویژگی در مجموعه آزمون چه مقدار MAE را افزایش می‌دهد. بنابراین غلبه فقط در محدوده توزیع داده‌ها و مدل آموزش دیده حاضر معتبر است.



شکل ۶

اهمیت جایگشتی ویژگی‌ها برای SVR با ۳۰ تکرار

ویژگی	افزایش میانگین MAE
r_{far}	24.947 m
r_{near}	9.309 m




ρ	0.699 m
θ_3	0.144 m
φ_{near}	0.131 m
φ_{far}	0.078 m
θ_2	0.061 m
θ_1	0.048 m

فاصله تجهیز دورتر مهم‌ترین عامل پیش‌بینی ارتفاع است. این نتیجه با شهود فیزیکی سازگار است: تجهیز دورتر معمولاً محدودکننده‌تر است و تغییر ارتفاع اثر بیشتری بر توازن دید مستقیم و افت مسیر آن دارد.

۱۳. مقایسه با مقاله Kang

برای مقایسه مستقیم، سناریوی اول مقاله با زاویه‌های هدف $[-40^\circ, 0^\circ, 40^\circ]$ ، زاویه تجهیزات $[-20^\circ, 20^\circ]$ و شبکه زاویه $0/1$ درجه اجرا شد. پنج مقدار ρ برابر $0/1$ ، $0/3$ ، $0/5$ ، $0/7$ و $0/9$ بررسی شدند.




شکل ۷

مقدار تابع هدف روش‌های ثابت، Algorithm ۲، Algorithm ۱، و SVR+P۲ روی شبکه مقاله

ρ	شکاف Algorithm ۲	شکاف SVR+P۲
0.1	3.084%	0.306%
0.3	1.697%	0.219%
0.5	0.847%	0.0038%
0.7	0.419%	0.082%
0.9	0.153%	0.092%

۱۳-۱. مقایسه ارتفاع‌های انتخاب‌شده



شکل ۸

ارتفاع انتخاب‌شده توسط روش‌های مختلف در پنج مقدار ρ

ρ	ارتفاع audit optimum	ارتفاع SVR
0.1	111.0 m	112.93 m
0.3	116.0 m	118.50 m
0.5	123.0 m	123.43 m
0.7	131.0 m	126.72 m
0.9	136.0 m	127.90 m

در ρ های ۰/۷ و ۰/۹ اختلاف ارتفاع بیشتر است، اما تابع هدف نسبت به ارتفاع در آن ناحیه نسبتاً تخت است؛ به همین دلیل شکاف تابع هدف همچنان زیر ۰/۱ درصد می‌ماند. این مثال به‌خوبی نشان می‌دهد که MAE ارتفاع همیشه معادل هزینه مهندسی نیست. Algorithm ۱ audit optimum یک بهینه ممیزی‌شده روی شبکه یک‌متری است و گواه رسمی بهینگی سراسری در ارتفاع پیوسته محسوب نمی‌شود.



۱۴. اعتبارسنجی و بازتولیدپذیری

علاوه بر معیارهای ML، مجموعه‌ای از آزمون‌های فیزیکی، عددی و بسته‌بندی اجرا شد. ۱۵ آزمون فیزیکی و ۶۷ آزمون تطبیق ادعاها با فایل‌های JSON/CSV همگی پاس شدند. شکل‌ها و نتایج در دو محیط مستقل مقایسه شدند.

نتیجه	لایه کنترل
PASS	ثابت‌های Kang و توان مطلوب
PASS	SDP بودن DCP/DPP
PASS	قطر ماتریس و قید PSD
PASS	تطبیق رابطه (۳۷)
$\max \text{gap} = 0.0168\%$	تکرارپذیری PSO
67/67 PASS	تطبیق ادعاهای گزارش
15/15 PASS	ممیزی فیزیک

اجرای لپ‌تاپ	مولفه
Windows 10	سیستم عامل
3.11.3	Python
2.2.6	NumPy
1.16.1	SciPy
1.9.2	CVXPY
0.11.1	Clarabel
1.7.1	scikit-learn
3.10.6	Matplotlib



تفاوت خروجی‌های عددی میان ۳.۱۱ Windows/Python و ۳.۱۲ Linux/Python در حد نویز نقطه

شناور بود. این موضوع اعتماد به بازتولیدپذیری عددی نتایج را افزایش می‌دهد.

۱۵. بحث، محدودیت‌ها و کار آینده

۱۵-۱. نقاط قوت

- پیوند مستقیم معیار ML با تابع هدف فیزیکی، نه اتکا به MAE به تنهایی.
- حفظ قیود شکل موج با یک حل دقیق پس از پیش‌بینی ارتفاع.
- ممیزی مستقل حل گر، برچسب، ادعا و مقایسه مقاله.
- ثبت سیدها و نتایج ساختاریافته برای بازتولید.

۱۵-۲. محدودیت‌ها

- داده‌ها شبیه‌سازی شده‌اند و آزمایش میدانی یا داده واقعی وجود ندارد.
- اعتبارسنجی خارج از توزیع انجام نشده است.
- برچسب‌های ارتفاع از یک جست‌وجوی گسسته و حل گر تقریبی تولید شده‌اند.
- ممیزی دقیق برچسب ۱۲ نمونه و ممیزی دقیق مدل‌ها ۲۰ نمونه را پوشش می‌دهد.
- مدل ML وزن‌ها یا ماتریس کوواریانس را مستقیماً پیش‌بینی نمی‌کند.
- یک حل SDP پس از پیش‌بینی باقی می‌ماند؛ بنابراین روش کاملاً solver-free نیست.
- زمان استنتاج صرف ML به‌طور مستقل گزارش نشده است.

۱۵-۳. مسیرهای پیشنهادی

افزایش اندازه داده، طراحی آزمون OOD، کالیبراسیون عدم قطعیت، استفاده از loss حساس به تابع هدف، پیش‌بینی ساختارهای امکان‌پذیر برای X و ارزیابی روی سخت‌افزار واقعی مهم‌ترین گام‌های بعدی هستند. PCA نیز در صورت الزام درسی می‌تواند به‌عنوان تحلیل مکمل اضافه شود، اما جایگزین اهمیت جایگشتی مدل نهایی نیست.

۱۶. جمع بندی

این پروژه نشان داد که بخش غیرمحدب جست و جوی ارتفاع در مسئله UAV-ISWPT را می توان با یک مدل رگرسیون سبک تقریب زد، بدون آن که قیود فیزیکی شکل موج حذف شوند. در ساختار نهایی، ML ارتفاع را پیشنهاد می دهد و یک حل دقیق P_2 شکل موج امکان پذیر را محاسبه می کند.

در ارزیابی پنج تقسیمی، SVR با MAE متوسط $7/88$ متر بهترین پایداری را داشت. در 200 نمونه آزمون، همین مدل کمترین شکاف متوسط تابع هدف، برابر $0/793$ درصد، را ثبت کرد. ممیزی دقیق 20 نمونه نشان داد MLP در آن زیرمجموعه شکاف متوسط کمتری دارد؛ نتیجه ای که اهمیت گزارش چند نوع ارزیابی و پرهیز از انتخاب گزینشی را نشان می دهد.

در سناریوی مقاله Kang، ترکیب SVR و یک حل P_2 در تمام پنج مقدار ρ کمتر از $0/307$ درصد از audit optimum فاصله داشت و از Algorithm ۲ محدود شده به جواب مرجع نزدیک تر بود. با وجود این، ادعای درست درباره پروژه «کاهش شدید جست و جوی بیرونی» است، نه «حذف کامل حل گر» یا «اثبات بهینگی سراسری پیوسته».

نتیجه نهایی: روش ترکیبی ارائه شده یک نقطه تعادل عملی میان سرعت، دقت و امکان پذیری فیزیکی ایجاد می کند و برای ادامه پژوهش در زمینه جانشین های آگاه از فیزیک مناسب است.

- [1] J. Kang, "Joint Design of Transmit Waveform and Altitude for Unmanned Aerial Vehicle-Enabled Integrated Sensing and Wireless Power Transfer Systems," *Electronics*, vol. 13, no. 21, 4237, 2024. DOI: 10.3390/electronics13214237.
- [2] Y. Chen, H. Hua, J. Xu, and D. W. K. Ng, "ISAC Meets SWIPT: Multi-functional Wireless Systems Integrating Sensing, Communication, and Powering," *arXiv:2211.10605*, 2023.
- [3] T. Chen et al., "Learning to Optimize: A Primer and A Benchmark," *Journal of Machine Learning Research*, vol. 23, no. 189, pp. 1–59, 2022.
- [4] M. Chen, U. Challita, W. Saad, C. Yin, and M. Debbah, "Artificial Neural Networks-Based Machine Learning for Wireless Networks: A Tutorial," *IEEE Communications Surveys & Tutorials*, vol. 21, no. 4, pp. 3039–3071, 2019.
- [5] S. Boyd and L. Vandenberghe, *Convex Optimization*. Cambridge University Press, 2004.
- [6] Scikit-learn Developers, "Scikit-learn: Machine Learning in Python," project documentation; models used: LinearRegression, DecisionTreeRegressor, SVR, and MLPRegressor.
- [7] CVXPY Developers, "CVXPY: A Python-Embedded Modeling Language for Convex Optimization," project documentation.

فایل‌های اصلی پروژه

01_Dataset_Generation.ipynb
02_Complete_ML_Analysis.ipynb
kang.py, fast.py, reference_solver.py, algorithm2.py
evaluate_ml_corrected.py, repeated_ml_metrics.py
benchmark_gap1.py, verify_gap1.py, validate_report_claims.py

پیوست: راهنمای اجرای پروژه

الف. اجرای سریع برای بررسی

۶. فایل‌های پروژه را در یک پوشه استخراج کنید.
۷. وابستگی‌ها را با دستور `python -m pip install -r requirements.txt` نصب کنید.
۸. نوت‌بوک `Complete_ML_Analysis.ipynb` را باز کنید.
۹. برای نمایش سریع خروجی‌های ذخیره‌شده، همه گزینه‌های `*_RUN` را `False` نگه دارید.
۱۰. سلول‌ها را از ابتدا به ترتیب اجرا کنید و شکل‌های ذخیره‌شده را مشاهده کنید.

ب. بازتولید محاسبات سنگین

فعال کردن هر گزینه `*_RUN` باعث اجرای دوباره بخش متناظر می‌شود. تولید دیتاست و ممیزی‌های دقیق زمان‌بر هستند و بهتر است جداگانه اجرا شوند. برای تولید داده جدید، از `Dataset_Generation.ipynb` و گزینه `RUN_ONE_CHUNK=True` استفاده شود.

•